DATASCAPE
FROM RAW DATA TO REAL IMPACT

RESI (Rotation-invariant regrouping, EMA stabilized, Source-aware relabeling, Inconsistent-label pruning)

Robust Package Condition Classification melalui Source-Aware Cleaning dan Rotation-Invariant Twin Grouping

Presented by **NamaTim**



Riantama Putra



Farrel Athalla Putra



Ayu Nagita Cahya


DATASCAPE
FROM RAW DATA TO REAL IMPACT
Pemahaman Masalah

Nilai Strategis QC Paket

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Kebutuhan Bisnis



Kerusakan fisik paket (**penyok, sobek, basah**) menjadi **kerugian finansial** sekaligus menggerus kepercayaan konsumen.



Foto QC dari kurir dan hub masih **diperiksa manual**, sehingga lambat dan **tidak konsisten antar petugas**



Jutaan paket melintasi rantai pasok setiap hari dan membutuhkan **penilaian otomatis dari satu foto.**

Dari Foto menjadi Keputusan QC



Paket Rusak

Satu foto paket diklasifikasikan menjadi **Aman, Rusak, atau Lainnya**, sehingga paket rusak dapat **ditahan sebelum sampai** ke pelanggan

Manfaat yang Diharapkan



Penyaringan Paket Lebih Cepat



Keputusan QC Lebih Konsisten



Petugas Fokus ke Kasus Sulit

Pemahaman Masalah

DATASCAPE
FROM RAW DATA TO REAL IMPACT

1



Kerusakan sering berupa **detail kecil** seperti penyok atau sobekan di tepi dus, sementara **dus utuh tampak serupa**.

2

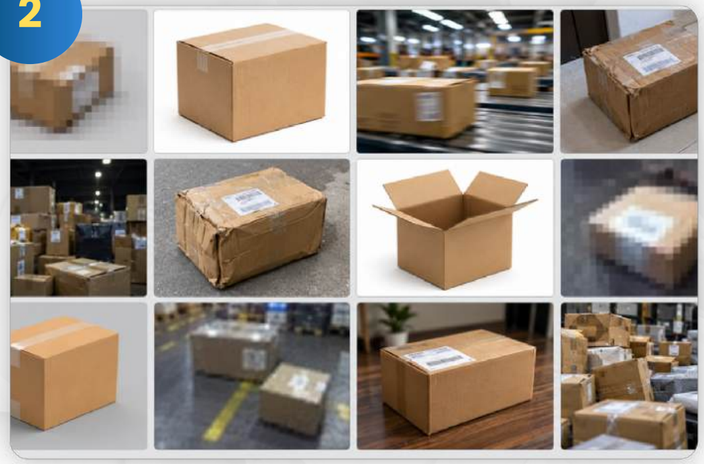


Foto datang dari **banyak sumber** (kurir, hub, katalog, render) dengan ukuran **37 sampai 4.500 piksel**.

3



Kemasan non-standar (**Lainnya**) hanya **3,5% data**, tetapi bernilai **sepertiga** Macro F1.

Key Takeaway

Diperlukan model yang ***robust*** **terhadap sumber foto baru** dan tetap **presisi pada kelas minoritas** untuk mendukung QC **paket otomatis** di hub logistik.

Tinjau Kilas Dataset

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Klarifikasi Citra



Rusak_02215.jpg

Aman

Rusak

Lainnya

Aman

Dus utuh, mulus, layak kirim.

Rusak

Penyok, sobek, basah, atau hancur.

Lainnya

Kemasan non-standar seperti kemasan makanan, kantong plastik, atau paper bag.

Metrik Evaluasi

$$F1_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

$$\text{Macro } F1 = \frac{F1_{\text{Aman}} + F1_{\text{Rusak}} + F1_{\text{Lainnya}}}{3}$$

Rata-rata F1 tiga kelas **tanpa bobot,** sehingga kesalahan pada kelas kecil **sama mahalnya** dengan kelas besar.

Kunci Masalah

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Baseline mentok di Macro F1 0,730!

0,730
Macro F1 00F baseline

0,600
F1 kelas lainnya

0,437
Presisi kelas lainnya

Fitur *frozen* sudah menangkap hampir semua kemasan Lainnya **(recall 0,955)**, tetapi **lebih dari 50% tebakannya salah.**

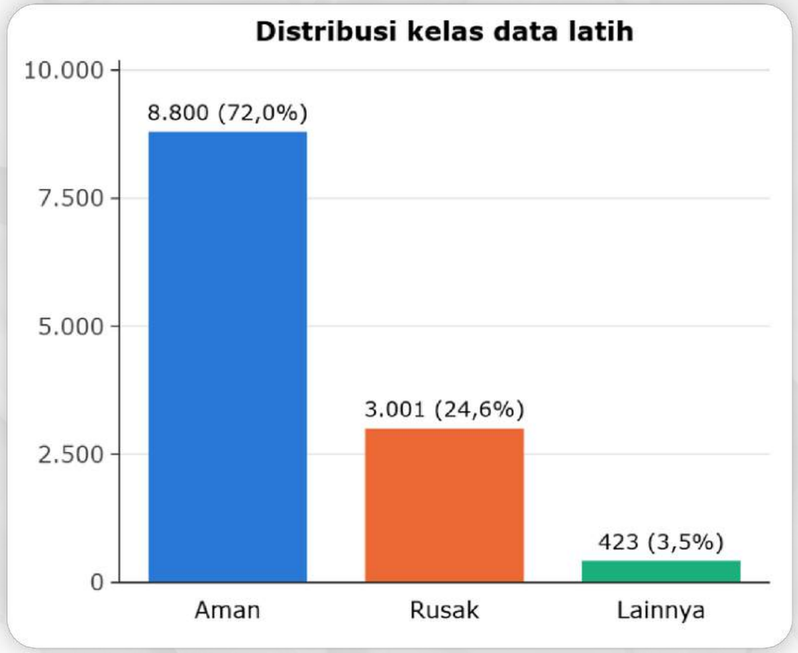
Apa yang salah di data, dan bagian model mana yang perlu beradaptasi?

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Exploratory Data Analysis

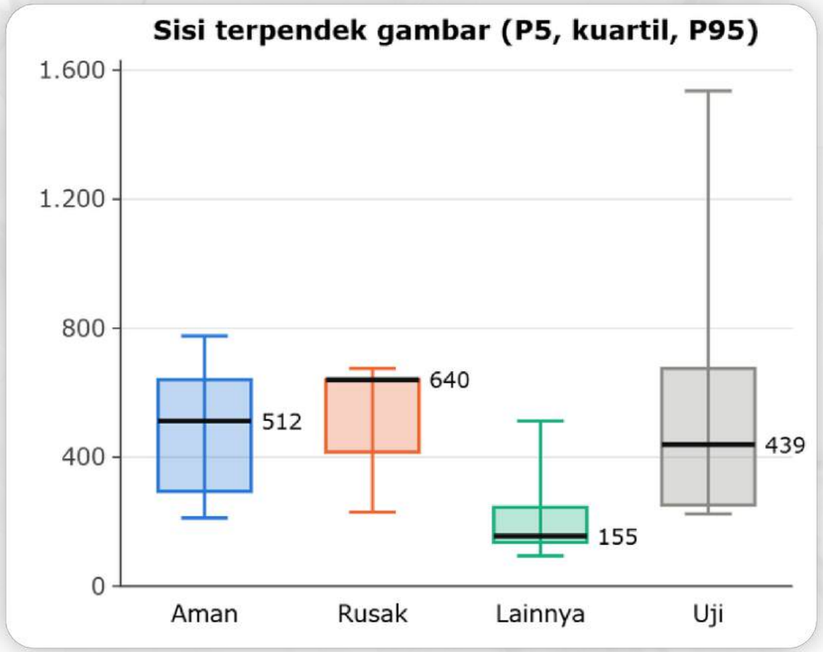
Distribusi Kelas dan Ukuran Gambar

DATASCAPE
FROM RAW DATA TO REAL IMPACT



Key Takeaway

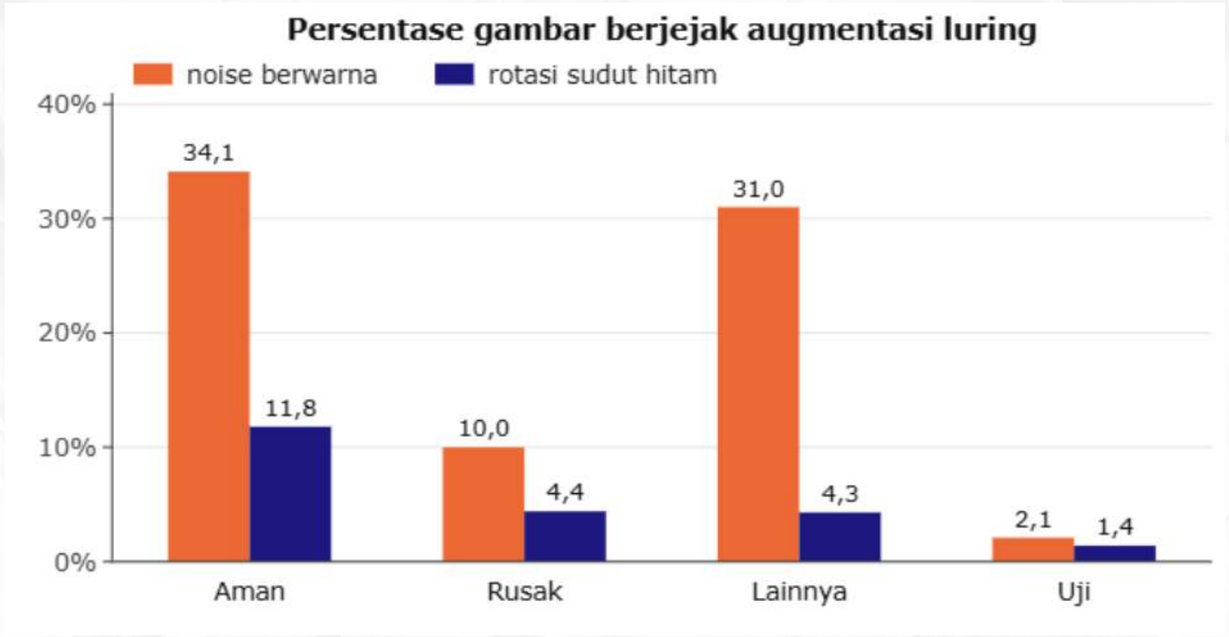
Terdapat ***imbalance data*** dimana rasio kelas Aman, Rusak, dan Lainnya adalah 20 : 7 : 1, dengan kelas Aman yang mendominasi sehingga diperlukan seperti ***class weighting*** untuk menangani masalah ini.



Key Takeaway

Masing-masing kelas **memiliki kriteria size nya tersendiri.** Perlu dilakukan *resize* agar ukuran asli tidak menjadi petunjuk kelas.

Data ter-Augmentasi





Contoh foto latih ber-noise dan hasil rotasi bersudut hitam

Key Takeaway

Terdapat data pada train yang **telah teraugmentasi** dari sananya. Jika dibiarkan, maka model dapat menghafal noise yang ada pada gambar sebagai sinyal klasifikasi.

Perlu diberikan noise, rotasi, dan grayscale acak ke semua kelas saat pelatihan, sehingga jejak augmentasi luring tidak lagi menjadi penanda kelas.

Jawaban dari Masalah

1



Contoh 1 | Train | Aman
Aman_08249.jpg



Contoh 1 | Train | Aman
Aman_08385.jpg



Contoh 2 | Train | Rusak
Rusak_01996.jpg



Contoh 2 | Train | Rusak
Rusak_01997.jpg



Contoh 3 | Train | Rusak
Rusak_02469.jpg



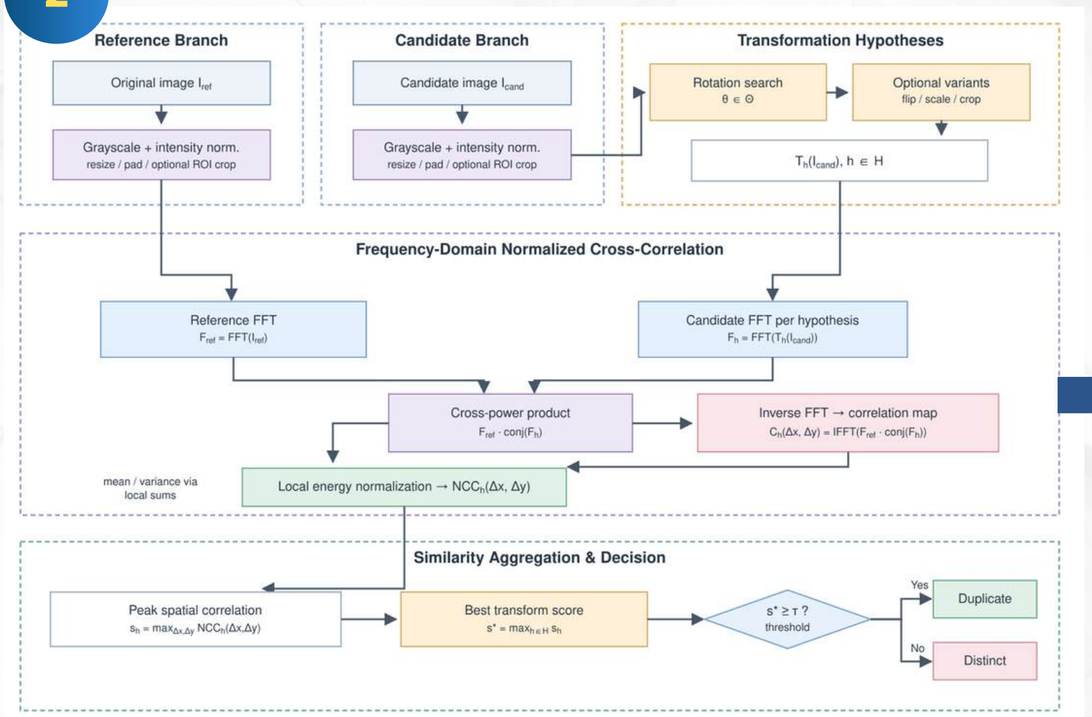
Contoh 3 | Train | Rusak
Rusak_02470.jpg

Key Takeaway

Degan ***perceptual hash*** ditemukan ***24,1% exact duplicate data*** pada dataset. Perlakuan *random split* pada training sangat berpotensi untuk menghasilkan model yang ***overfit*** akibat menghafal

Jawaban dari Masalah

2





Key Takeaway

Dengan **Polar FFT + NCC threshold 0,93** ditemukan tambahan **7.769 pasangan** hasil rotasi dan cermin yang lolos dari hash.

Jawaban dari Masalah

3



Contoh 1 | Train | Aman
Aman_06765.jpg



Contoh 1 | Train | Rusak
Rusak_01896.jpg



Contoh 2 | Train | Aman
Aman_07807.jpg



Contoh 2 | Train | Rusak
Rusak_02101.jpg



Contoh 3 | Train | Aman
Aman_07559.jpg



Contoh 3 | Train | Rusak
Rusak_01962.jpg

Key Takeaway

Terdapat gambar duplikat yang berada pada **kelas yang berbeda,** sehingga dapat menyebabkan ***gradient conflict*** dan **loss besar** pada model.

Jawaban dari Masalah

4



Aman → Rusak (usulan)
Aman_07808.jpg



Rusak → Aman (usulan)
Rusak_01900.jpg



Aman → Lainnya (usulan)
Aman_06056.jpg

Key Takeaway

Mislabel pada data menyebabkan kesalahan pembelajaran pada model sehingga model menangkap **pola yang salah** untuk setiap kelas.

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Kerangka Percobaan

Workflow Diagram

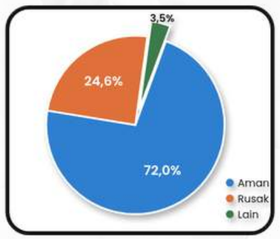
DATASCAPE
FROM RAW DATA TO REAL IMPACT

Dataset



Datascape 2026
15.281 foto paket: 12.224 latih dalam 3 kelas dan 3.057 uji tanpa label

Exploration



Peninjauan Karakteristik
Audit duplikat MD5, kembaran rotasi, dan ketimpangan kelas.

Preprocessing

Data Cleaning (R · S · I)

+

Resize 320 + Augmentasi

Pemrosesan Data
Pembersihan menyisakan 11.299 gambar, lalu *resize* tanpa *crop*

Skema Validasi

Train | **Val**

5 fold StratifiedGroupKFold, grup kembaran tidak terbelah.

Pengembangan Model

Eksplorasi *probe* linear pada fitur DINOv3 beku hingga *fine-tuning* enam blok ViT-7B/16

Configs:

Blok dibuka?
Focal Loss + Smoothing?
Bobot EMA?

Evaluasi

Macro F1 out-of-fold dengan skor EMA, rata-rata 0,9352

Best Model

Dilatih ulang pada 100% data bersih selama 9 epoch untuk submisi akhir

Prediksi Test Set + TTA



Analisis Pasca

Matriks konfusi OOF dan error per sumber foto

DATASCAPE
FROM RAW DATA TO REAL IMPACT

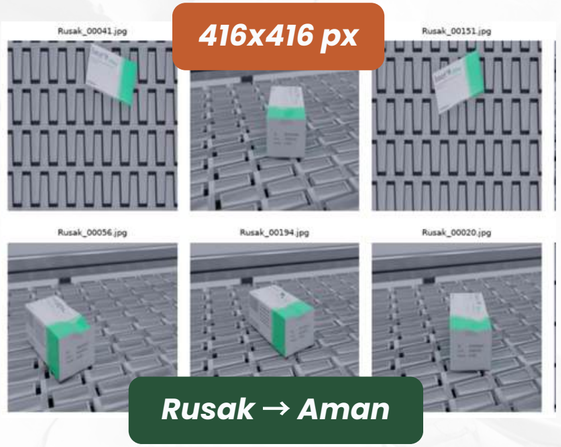
Data Preparation

Pembersihan Label



Menghapus Gambar dengan Label Konflik

Karena hanya terdapat 26 pasangan gambar dengan label konflik dan menentukan kelas yang tepat perlu secara manual, maka menghapus menjadi opsi paling **aman dan efisien**.



Greedy Relabel Method

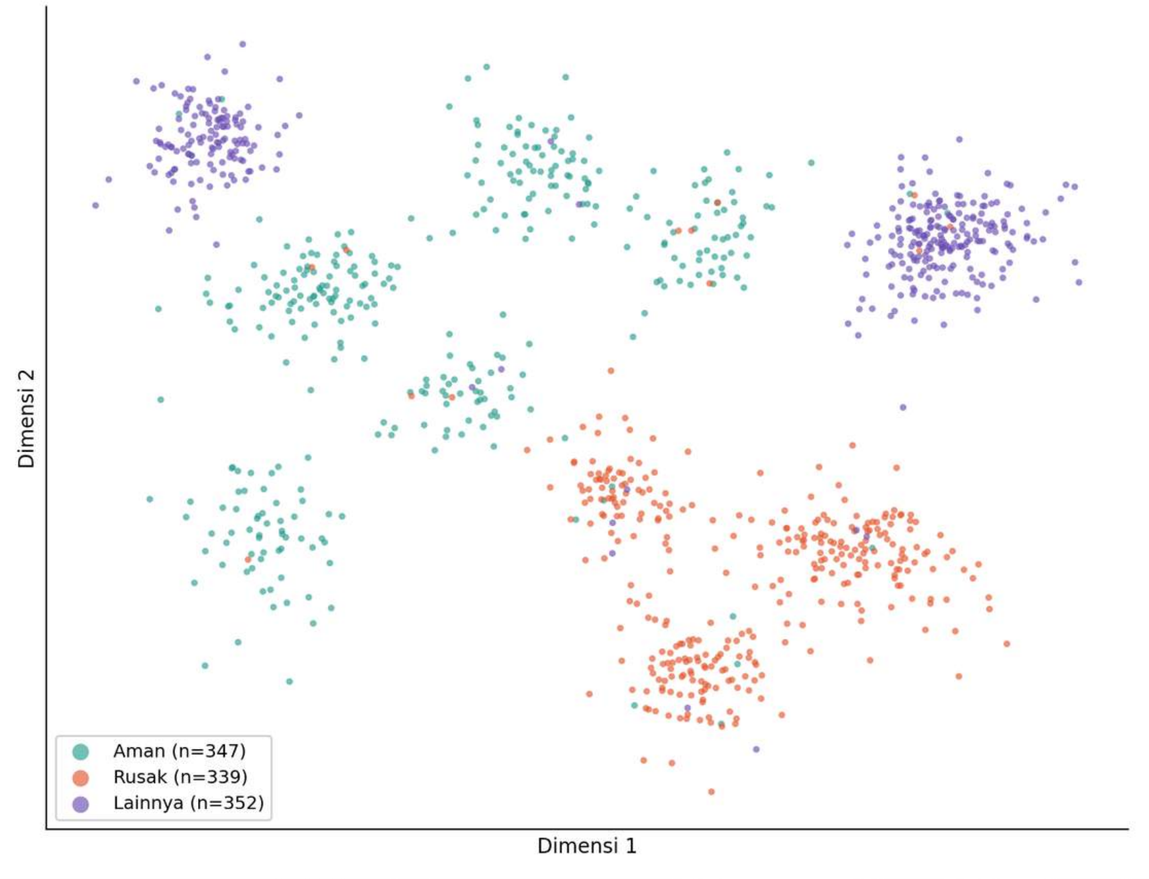
Gambar dengan ukuran tertentu yang sudah diseleksi manual diubah ke kelas yang tepat



Pembersihan Label

DATASCAPE
FROM RAW DATA TO REAL IMPACT

DINOv3 frozen embedding K-means clustering



1.038 gambar yang telah divalidasi manual

↓

DINOv3 embedding

↓

K-means clustering

↓

Cluster sisa data

Pembersihan Label

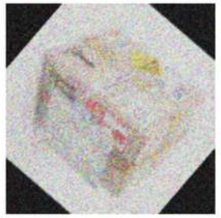
DATASCAPE
FROM RAW DATA TO REAL IMPACT

Dataset Akhir

Aman_00096.jpg
1712x963



Aman_00593.jpg
512x512



Aman_04991.jpg
267x268



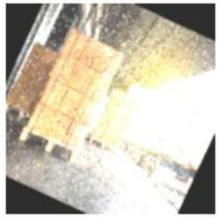
Aman_08331.jpg
736x736



Aman_00361.jpg
299x168



Aman_03502.jpg
224x224



Aman_01781.jpg
736x1308



Aman_06816.jpg
263x263



Aman_04099.jpg
677x677



Aman_06634.jpg
69x46



Aman_00995.jpg
51x38



Aman_00081.jpg
800x800



Rusak_01802.jpg
640x640



Rusak_01191.jpg
365x251



Rusak_01412.jpg
640x640



Rusak_02114.jpg
640x640



Lainnya_00146.jpg
136x200



Lainnya_00281.jpg
160x200



Lainnya_00133.jpg
200x200

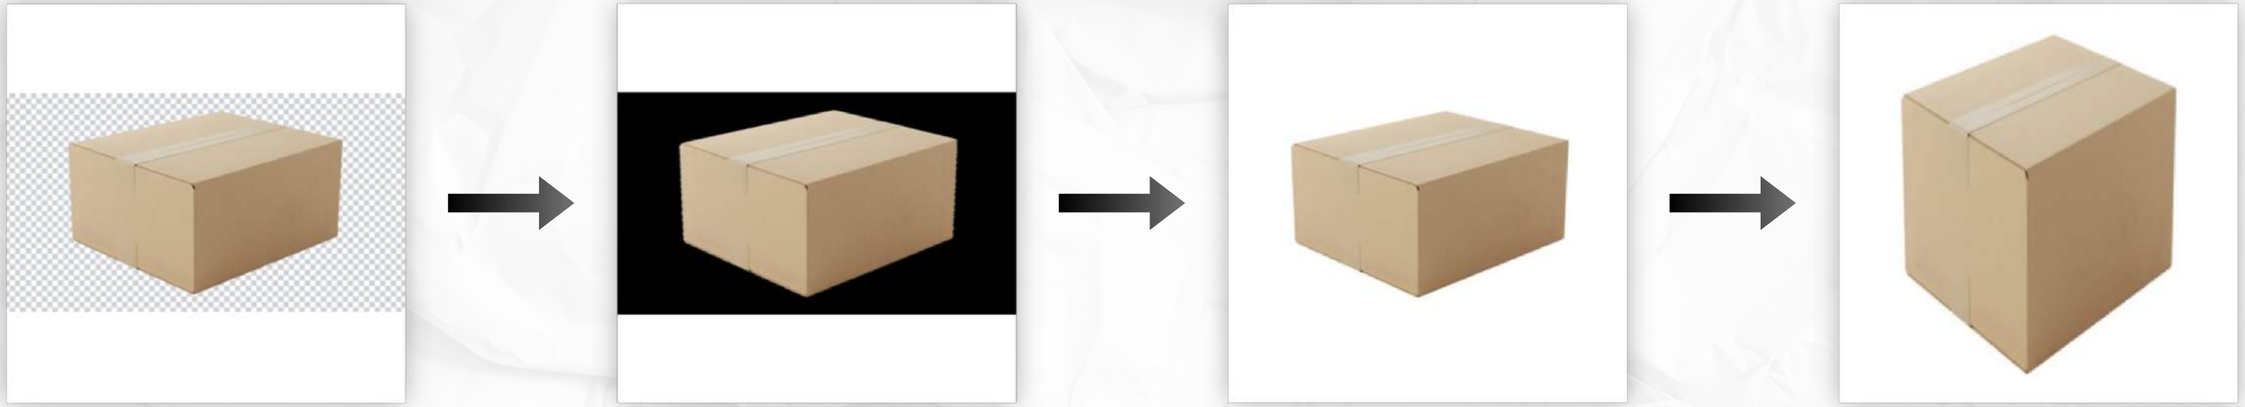


Lainnya_00138.jpg
142x200



Preprocessing

DATASCAPE
FROM RAW DATA TO REAL IMPACT



Berkas asli (PNG, RGBA) → **Konversi RGB langsung** → **Alpha ke latar putih** → **Resize ke 320 x 320**

Contoh: test_01625.jpg dari data uji, 57,5% area transparan

Key Takeaway

Format dikenali **dari isi berkas**, karena 1.388 berkas latih dan 615 berkas uji ternyata salah ekstensi. Kanal alpha **digabung di atas latar putih**, sebab konversi langsung memunculkan latar hitam. Gambar lalu **di-resize langsung ke 320** tanpa center crop dan **dinormalisasi** dengan mean/std ImageNet, sama seperti image processor resmi DINOv3.

Augmentasi

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Tipe Augmentasi



Gambar asli



Crop 62%



Cermin



Rotasi 25



Noise



Grayscale



Color jitter



Gaussian Blur

On the Fly Augmentation

#1



#2



#3



Tiga kombinasi acak dari foto Rusak yang sama: crop, cermin, rotasi, warna, noise, dan grayscale dipilih ulang setiap kali gambar ditarik.

Key Takeaway

Augmentasi melalui **crop minimal 60% dan cermin** untuk variasi posisi, **color jitter dan blur** untuk variasi kamera, serta **noise, rotasi 25°, dan grayscale** yang disebar ke semua kelas agar jejak luring tidak menjadi penanda.

Key Takeaway

Setiap epoch menghasilkan **kombinasi acak baru** dari foto yang sama, sehingga model tidak menghafal satu tampilan.

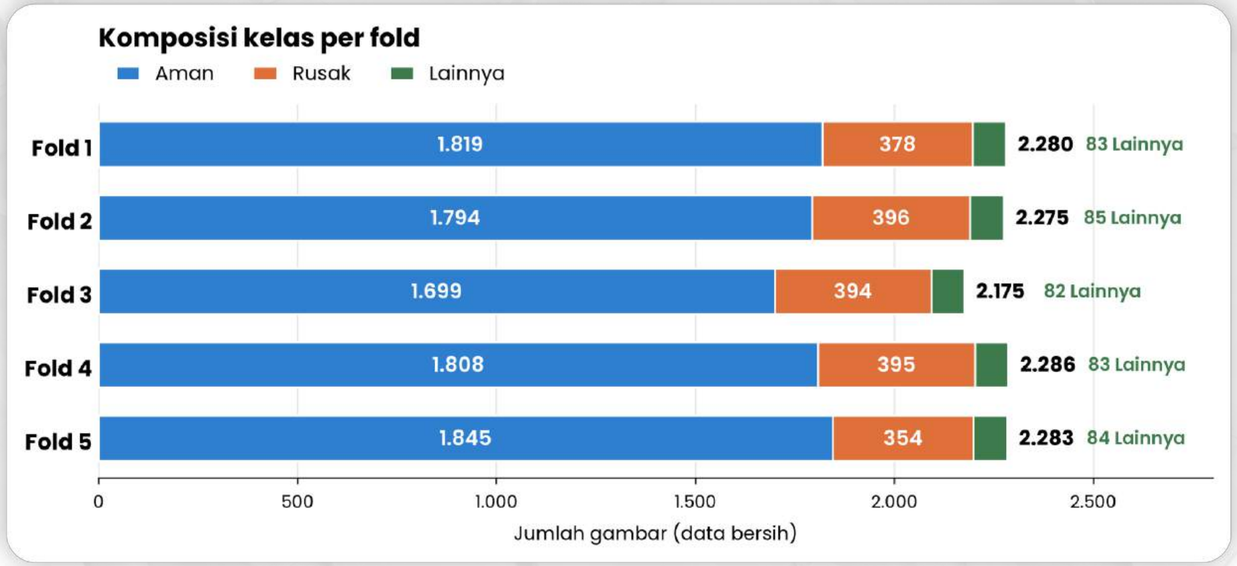
DATASCAPE
FROM RAW DATA TO REAL IMPACT

Modelling

Skema Validasi

DATASCAPE
FROM RAW DATA TO REAL IMPACT

5-Fold StratifiedGroupKFold + Grup Kembaran



	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Model 1	VAL	TRAIN	TRAIN	TRAIN	TRAIN
Model 2	TRAIN	VAL	TRAIN	TRAIN	TRAIN
Model 3	TRAIN	TRAIN	VAL	TRAIN	TRAIN
Model 4	TRAIN	TRAIN	TRAIN	VAL	TRAIN
Model 5	TRAIN	TRAIN	TRAIN	TRAIN	VAL

*Satu grup kembaran (7.924) selalu berada di sisi yang sama: yaitu **train** atau **validation***

Prediksi OOF Tiap Fold

Prediksi OOF per gambar → ***EMA, epoch terbaik*** → **Prediksi OOF per gambar**

Metrik Evaluasi

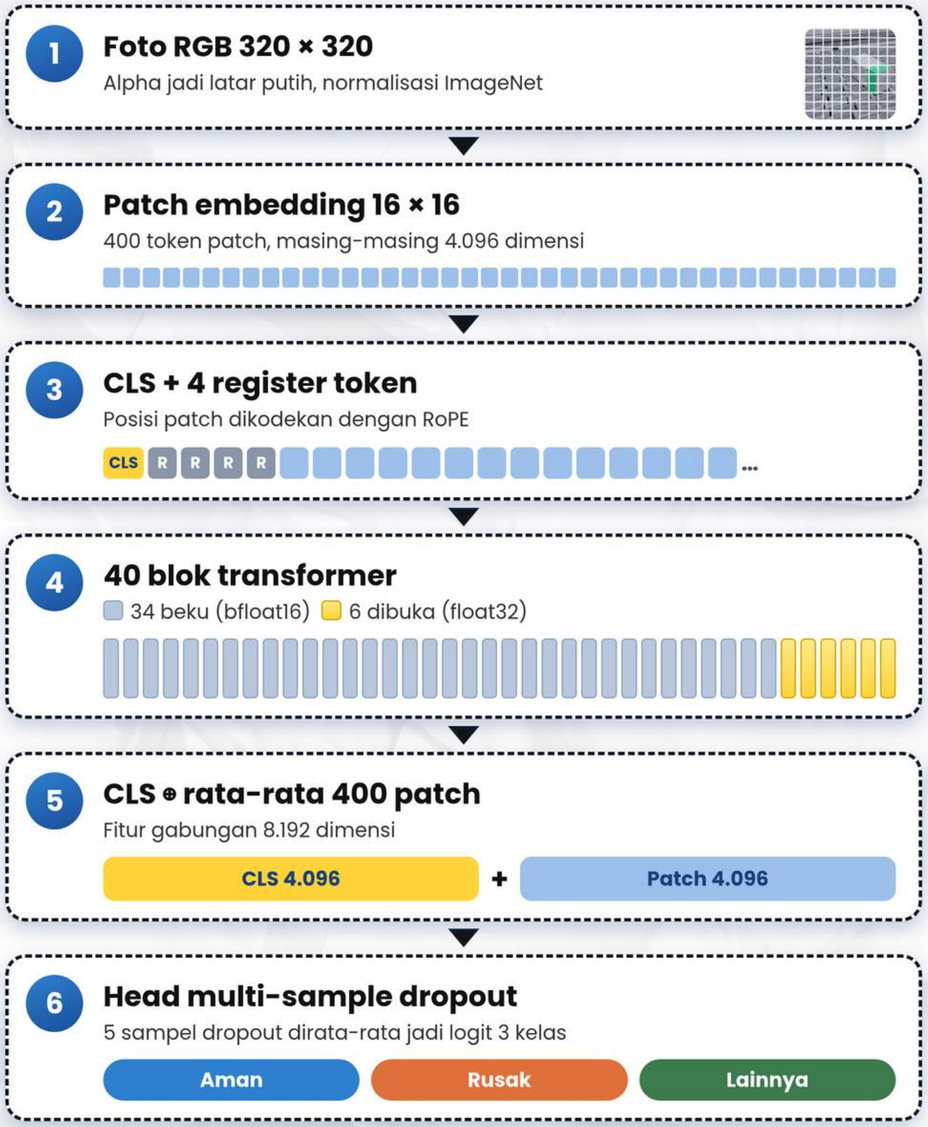
$$\text{Macro } F1 = \frac{F1_{\text{Aman}} + F1_{\text{Rusak}} + F1_{\text{Lainnya}}}{3}$$

Dihitung dari prediksi OOF seluruh 11.299 gambar

Key Takeaway

Median epoch terbaik 5 fold (9 epoch) dipakai untuk pelatihan ulang pada 100% data bersih.

DINOv3



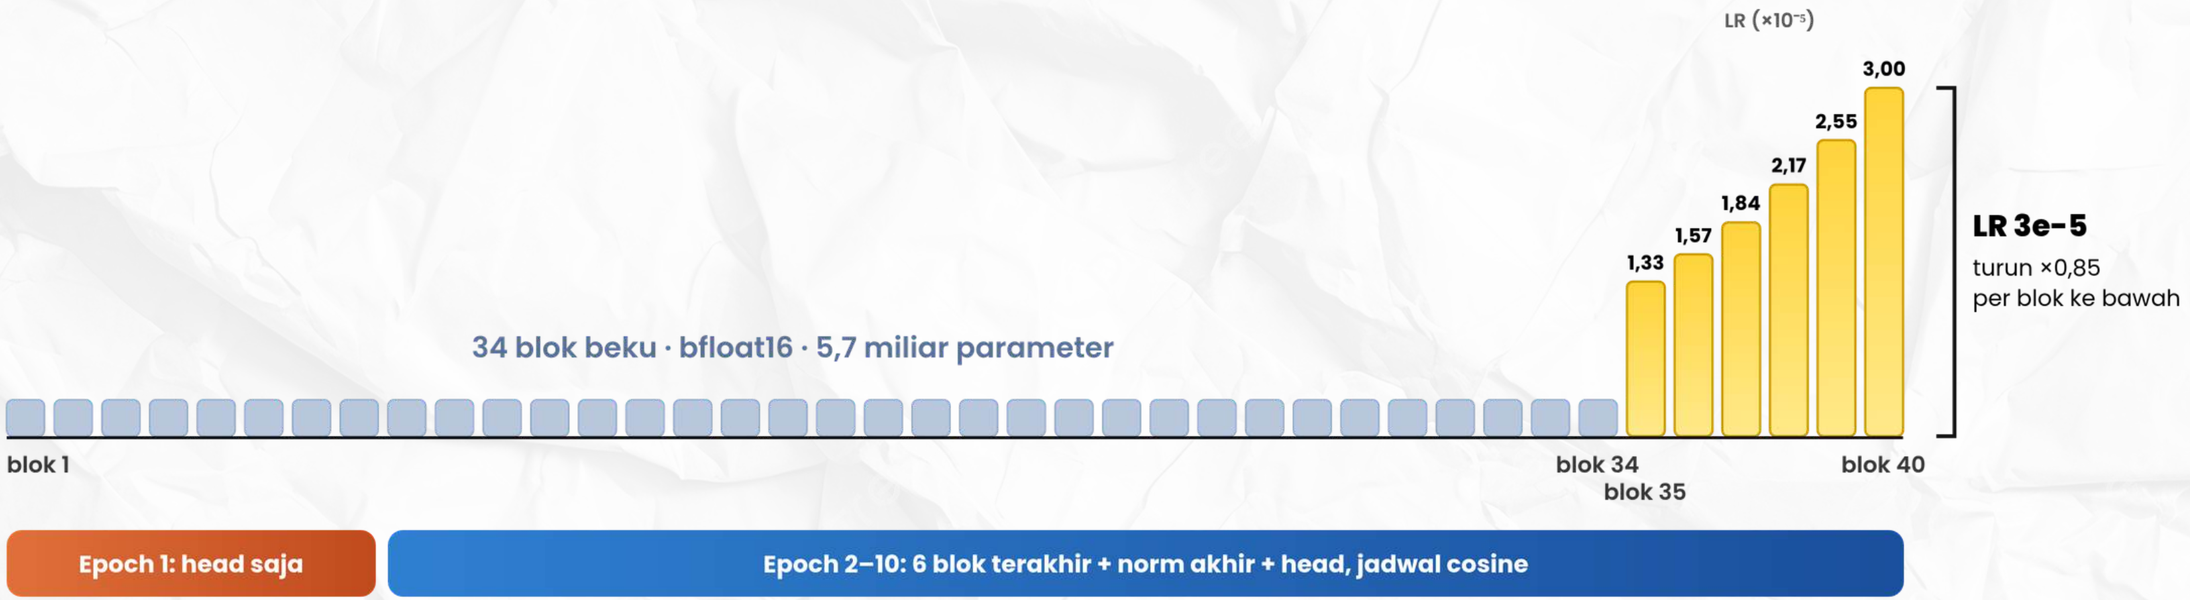
Prinsip Kerja

DINOv3 ViT-7B/16 membagi foto 320 x 320 menjadi **400 patch 16 x 16** berdimensi **4.096**. Token diproses **40 blok transformer** (6,7 miliar parameter) yang dilatih self-supervised pada **1,689 miliar gambar (LVD-1689M)**. Token **CLS** dan **rata-rata patch** digabung menjadi fitur **8.192 dimensi** untuk head

Kelebihan

- **Fitur umum** dari 1,689 miliar gambar membuat model **tahan terhadap sumber foto baru** di data uji.
- Token CLS menangkap **konteks global**, rata-rata patch menangkap **detail lokal** seperti sobekan.
- Probe beku saja sudah **0,730**, fondasi kuat sebelum fine-tuning.

Fine-tuning Parsial dan Head MSD



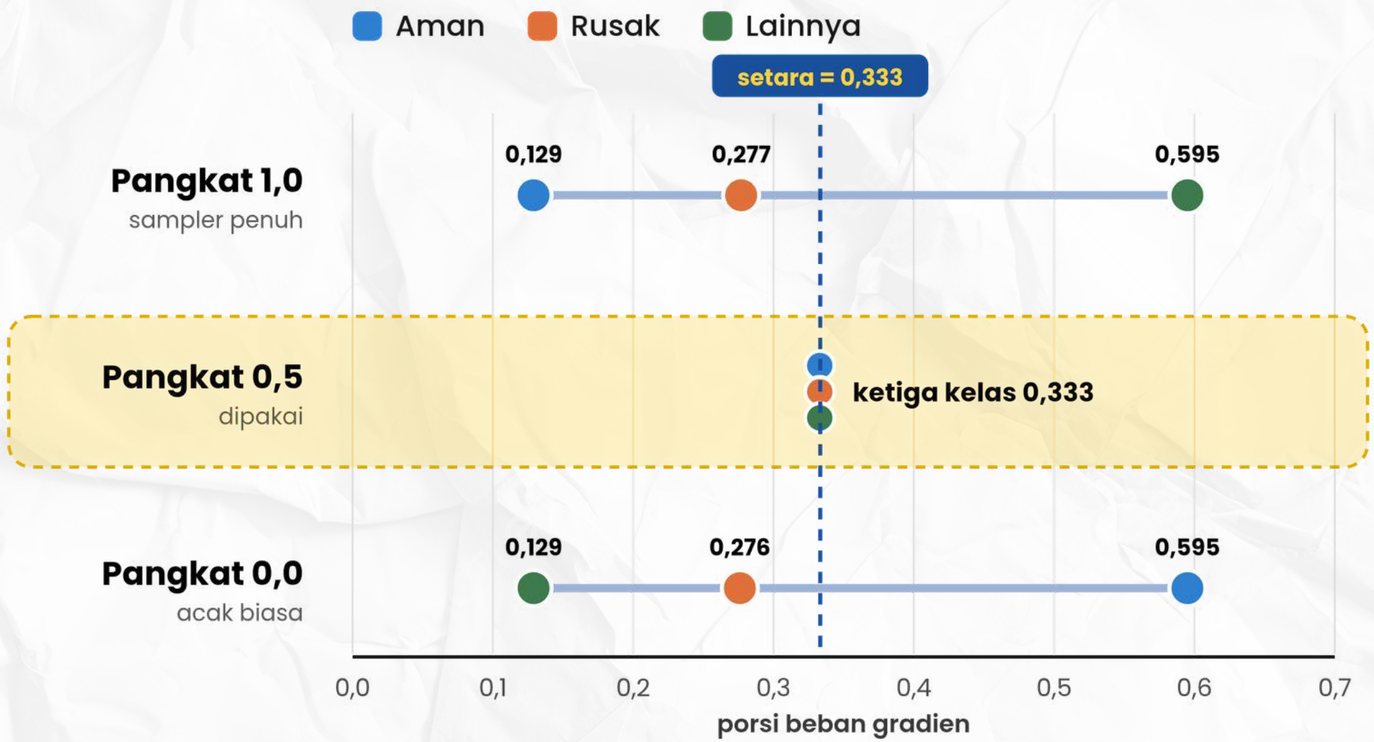
Prinsip Kerja

34 blok pertama **dibekukan**, 6 blok terakhir dan norm akhir **dibuka dalam float32** (1,0 miliar parameter). Head **multi-sample dropout** merata-ratakan logit dari 5 dropout mask. Bobot dirata-rata dengan **EMA 0,999** untuk evaluasi

Kelebihan

- **Hemat memori:** model 6,7 miliar parameter muat di satu GPU 96 GB.
- Head acak di epoch pertama **tidak merusak** fitur pra-latih.
- Blok atas belajar **detail dus dan resi**, blok bawah menjaga fitur umum.

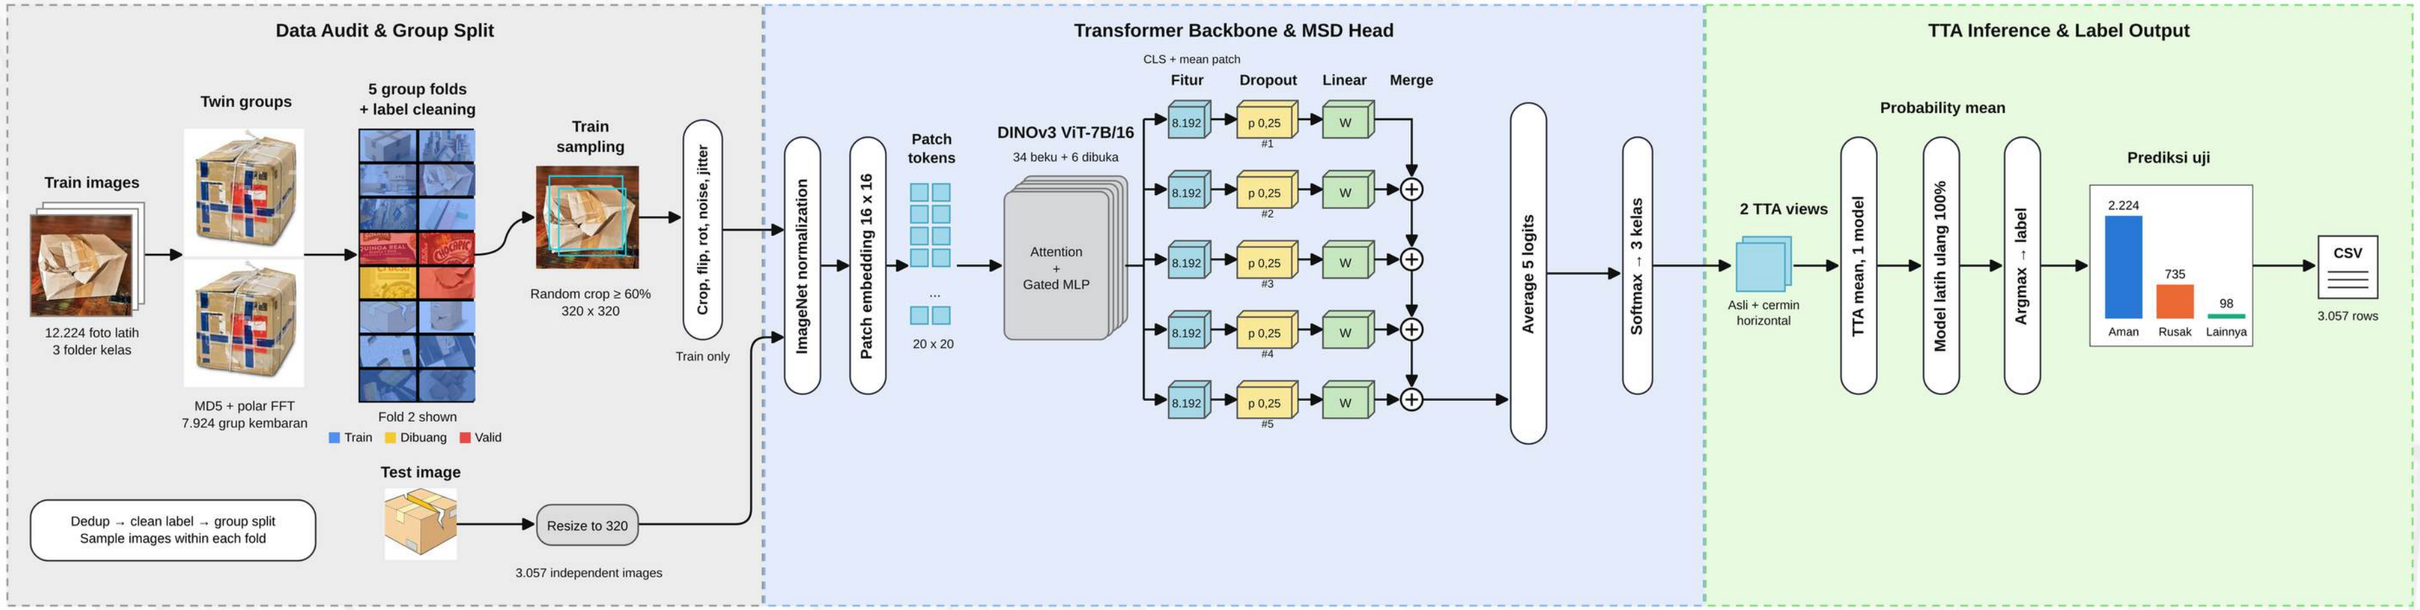
Focal Loss dan Bobot Kelas



Key Takeaway

Saat **pt** = 0,9, loss tinggal **1%** dari cross-entropy biasa, sehingga gradien terpusat pada **foto sulit**. Sampler penuh ditambah alpha memberi Lainnya **60% beban gradien** padahal datanya 3,7%; **pangkat 0,5** membuat ketiga kelas berbagi beban **setara**.

RESI Framework



Data Preparation & Cleaning

Seluruh berkas diaudit, kembaran rotasi dan cermin dikelompokkan, lalu label dibersihkan dengan **3 aturan** sebelum fold dibentuk per grup.

Feature Extraction

DINOv3 ViT-7B/16 mengekstrak fitur global dan lokal; hanya 6 blok terakhir dan head yang dilatih dengan **focal loss** dan sampler berbobot.

Inference and Submission

Model hasil latih ulang 100% data memprediksi foto uji dengan **TTA cermin**, lalu label dengan probabilitas tertinggi ditulis ke **submission.csv**.

RESI Benchmarking

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Konfigurasi	Data Latih	F1 Aman	F1 Rusak	F1 Lainnya	Macro F1 (OOF)	Kaggle Public / Private
DINOv3 Baseline	11.545	0,908	0,683	0,600	0,7303	tidak disubmit
ResNetV2 Baseline	11.545	0,872	0,584	0,469	0,6417	tidak disubmit
RESI + DINOv3	**11.299**	**0,983**	**0,930**	**0,892**	**0,9352** ↑ 0,2049	**0,96532 / 0,92663**
RESI + ResNetV2	11.299	0,962	0,861	0,781	0,8680	0,90417 / 0,86952

Key Takeaway

Backbone sama, fold grup sama. Membuka **6 dari 40 blok** dan membersihkan label menaikkan Macro F1 OOF sebesar **+0,205**, dengan lonjakan terbesar di **F1 Lainnya (0,600 ke 0,892)**. Masalahnya bukan fitur DINOv3, tetapi fitur yang dibekukan seluruhnya.

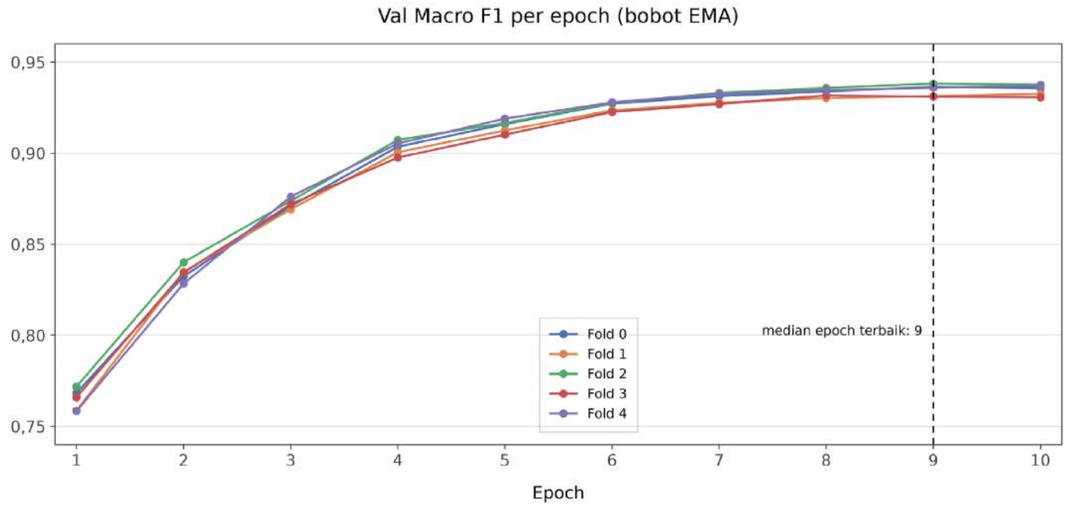
DATASCAPE
FROM RAW DATA TO REAL IMPACT

Hasil dan Analisis

Hasil Performa Model

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Lima fold mencapai Macro F1 0,9352 ± 0,0029 tanpa gap antar fold.



Fold	Epoch terbaik	Macro F1
0	9	0,9364
1	10	0,9326
2	9	0,9382
3	8	0,9317
4	10	0,9371
Rata-rata	9 (median)	**0,9352**

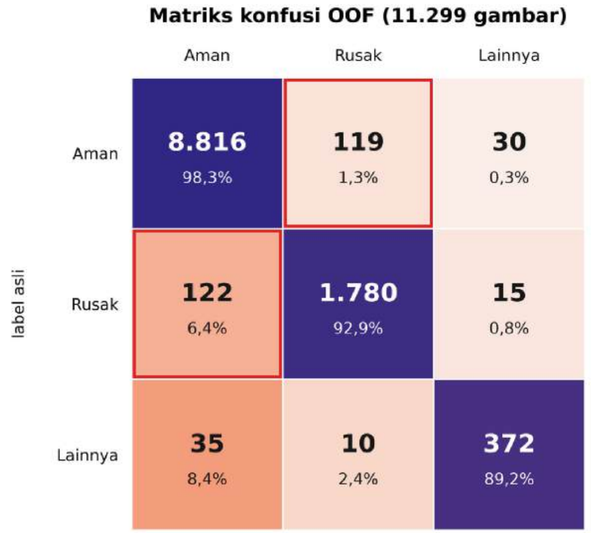
Key Takeaway

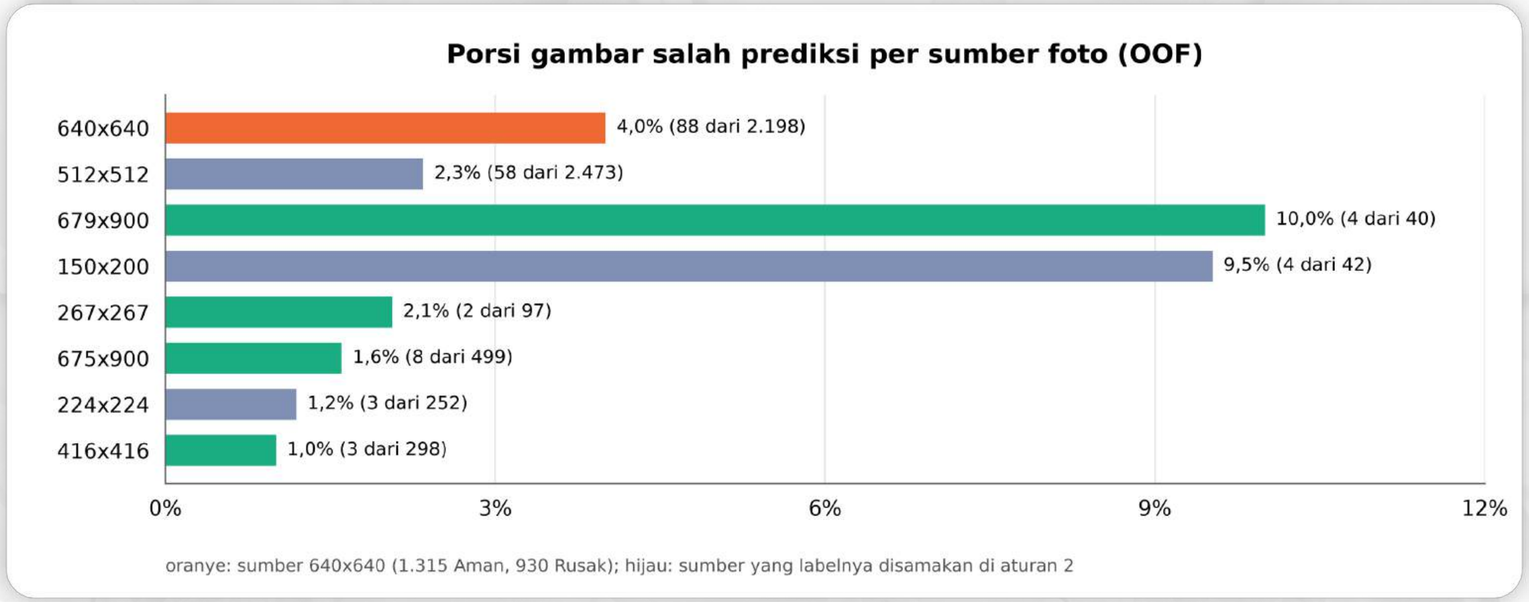
Menggunakan **DINOv3 ViT-7B/16** dengan 6 blok dibuka (input 320, **focal loss + label smoothing**, 10 epoch, EMA 0.999, augmentasi crop, cermin, rotasi, noise, dan warna), model meraih **OOF 0.9352** (Fold 0 sampai 4: 0.9364, 0.9326, 0.9382, 0.9317, 0.9371). Kurva yang berimpit menandakan skor **tidak bergantung pada keberuntungan split.**

Hasil Performa Model

DATASCAPE
FROM RAW DATA TO REAL IMPACT

Sebagian besar error ada ada di perbatasan Aman dan Rusak





Key Takeaway

241 dari 331 kesalahan OOF (73%) adalah Aman dan Rusak yang tertukar, umumnya kerusakan ringan yang ambigu. Sumber **640x640** yang labelnya memang bercampur menyumbang **88** kesalahan, sedangkan sumber yang labelnya disamakan (416x416 dan 675x900) hanya salah **1,0% dan 1,6%**. Akurasi total mencapai **97,1%**.

Evaluasi





Key Takeaway

Kesalahan OOF (kiri) umumnya foto **ambigu atau berjejak augmentasi** seperti noise, rotasi, dan grayscale, serta label yang memang meragukan seperti dus bertuliskan ***Damaged Packaging*** yang tampak utuh. Gambar yang dibuang probe (kanan) didominasi **poster, infografis, dan foto non-paket** yang labelnya tidak sesuai isi.

Kesimpulan & Arah Pengembangan

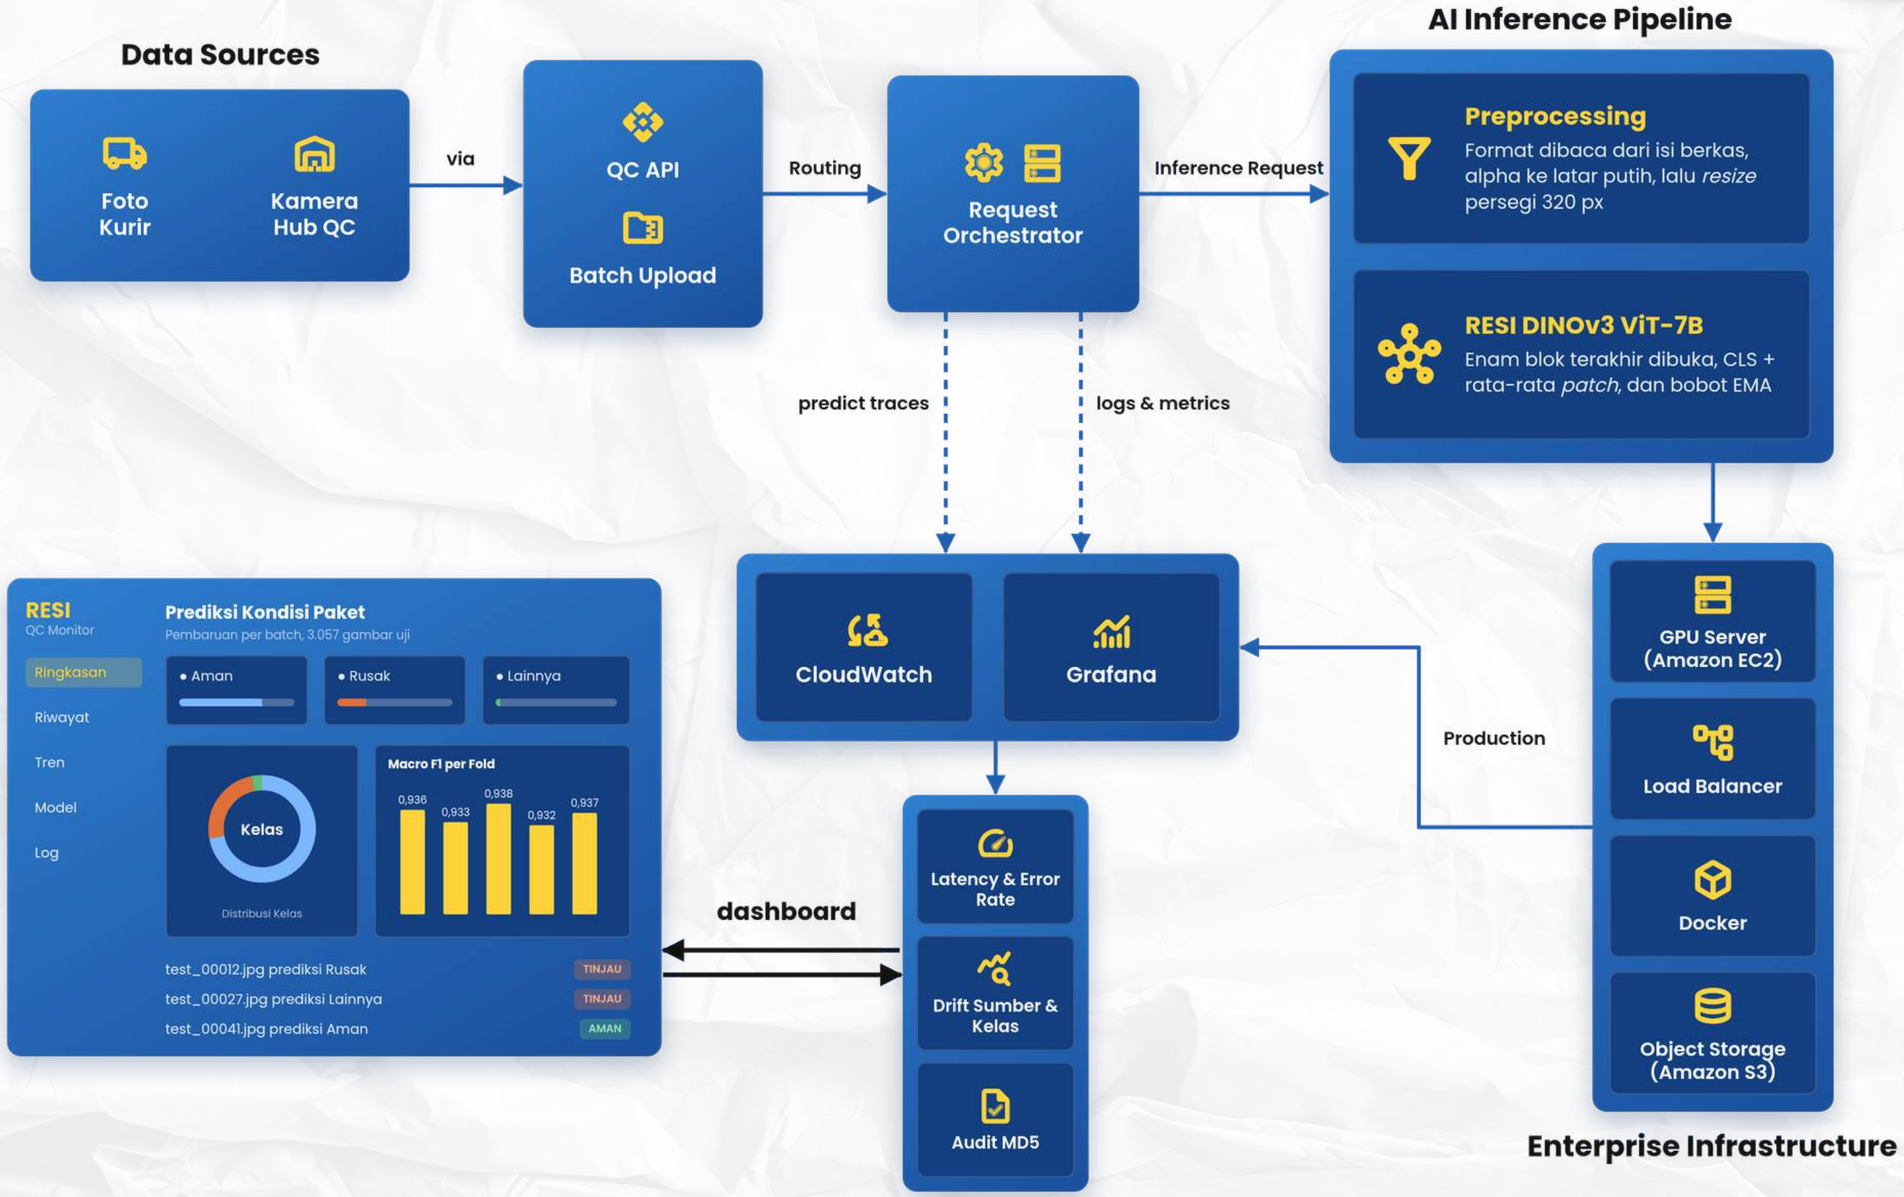
DATASCAPE
FROM RAW DATA TO REAL IMPACT

RESI mencapai Macro F1 OOF 0,9352 dan 0,92663 di private leaderboard. Validasi berbasis grup kembaran membuat skor lokal dekat dengan skor privat.

Kualitas data menentukan skor lebih dari arsitektur. Kembaran rotasi, label per sumber, dan jejak augmentasi luring harus ditangani sebelum pelatihan.

Pengembangan diarahkan pada distilasi ke ViT kecil untuk QC real-time di hub. Model DINOv3 saat ini menjadi guru, ditambah relabel aktif untuk foto yang modelnya ragu.

Arsitektur MLOps




Terima
Kasih!